

- protocol vector a complete data - old -

data mining = extracting information from data  
= utilizing SQL queries  
= "data mining"

machine learning = utilizing statistical data processing  
elements directly

KDD = knowledge discovery in database

- transforming data into information

DM

1. data preprocessing

2. data mining

3. post processing

⑤ optimization

ML

1. data preprocessing

2. feature selection (using attribute)

3. using various ML

4. training (learning)

5. evaluation

- ML is a subset / consists AI

- proc ?      Substrat (wort)

Complexität

Dimension

wie z.B. 2D

- prediktiv

→ primäre Ziel

- hochgradig adaptiv  
z.B. 1D, 2D, 3D

- deskriptiv

→ DTP

- populäre Services: u. d. d. d.

1. ceteris paribus

2. ceteris paribus

3. z.B. 1D, 2D, 3D

4. ceteris paribus

1. Klassifizierung

2. Regression

ML

1. assoziativ (z.B. 1D, 2D, 3D)

2. Substrat (z.B. 1D, 2D, 3D)

3. Daten (z.B. 1D, 2D, 3D)

DTP



- hodnoty z- $\bar{x}$  a  $\bar{x}$

-  $t_{\alpha/2}$  z tabulky, vztlah

- nutná předzpracování

- při měření věku je třeba jen ID

data set = množina objektů

atribut = vlastnost

- objektivní to jsou faktory

- asymetrické atributy  $\Rightarrow$  dělíme je na nové hodnoty

1. kategorie (kvalitativní) =  $s_1 - s_5$

a. nominální - pouze odlišnost - ID, pohlaví

b. ordinální - srovnávání  $<, \geq, \dots$  - stupně učebny

2. numerické (kvantitativní) = čísla

a. intervalové - konstantní měna jednotka

b. poměrové - počet, délka

- diskrétní  $\rightarrow$  je srovnání možno

spojité  $\rightarrow$  třeba desetinné čísla

$r \in r_i G_n$        $\hookrightarrow j i r$        $\text{cl}(v)$        $\hookrightarrow$        $G_{\text{calit}}$  :     $d(\cdot) = z$

l.  $z^a z_{1-a} \rightarrow z^a$  falls

$\sim \delta_{\alpha\beta} \delta_{\gamma\delta}$      $\delta_{\alpha\beta}$      $= \delta_{\beta\alpha}$      $\delta_{\alpha\beta} \delta_{\gamma\delta} = \delta_{\beta\delta} \delta_{\alpha\gamma}$      $\delta_{\alpha\alpha} = 1$      $\delta_{\alpha\beta} \delta_{\beta\gamma} = \delta_{\alpha\gamma}$

2.  $f_1 = f_0 \cdot z^{-1}$   $df_1 = f_0$

$$- \cup q_1 = \zeta_1 \quad \cup \zeta_1 \quad \cup \zeta_2 \quad \cup \zeta_3 \quad \cup \zeta_4$$

3. c spici e der c' clet's

- u case ne So pu g/hu-

-  $45 \in \mathbb{R}$  „positiv“

- Untuk mencari perbedaan (variabel)

$$- \frac{e}{s_c} = a \, a_0 \, g \, b_{-1} \, b_{-2} \, b_{-3} \, b_{-4} \, b_{-5}$$

pievārtība

- method of ... with special ...
- position ...

- dissectione = splicing in dissection

binäre Zahl = Darstellung in binärer (one-bit encoding)

make - chemics 

-  $Le^{-i\vec{p}\cdot\vec{r}} = e^{-i\vec{p}\cdot\vec{r}}$  is a plane wave

stages  
512  
intervals, etc

$\frac{1}{\sin^2 \theta} \approx \frac{1}{\sin^2 \theta_0} + \frac{1}{\sin^2 \theta_0} \left( \frac{1}{\sin^2 \theta} - \frac{1}{\sin^2 \theta_0} \right)$



## Ērības koda atšifrēšana

- transformācija priekšapstrādes
- mazāks zīmējums, precīzāks kods.

### standardizācija

- abas ekstrēmās vērtības koda atšifrēšanas kods (piemēram:  $\min = 0$  un  $\max = 1$ , var būt arī citi)

## Preprocesēšana dat

### agregācija

- bināro koda do izveido
- kādā s. atn. sarakstā, piemēram, ...?

### uzdevu risināšana (sampling)

- mazāks kods izveido
- koda / statist. kods

### reducēšana dimenzionalitāte

- ir atšifrē
- kodējums, izveido i. kods
- kādā?
- feature creation un feature selection

• **Quality criteria**


**precision** - blizkost operacijskega sistema s stvarno svetom; skladnost oblik/ve

**bias** - skladnost sistema s stvarno svetom

**accuracy** - blizkost precision s stvarno svetom

**odlivi** - odložitve in izbire  
(- izbiranje)

- oblikovanje tehnike a. izbire doprinos / eliminiranje?



- konsistentnost tehnike → oblikovanje procesa  
(- izbiranje opreme)

**problematičnost a. blizkost**

- izbiranje sistema?

- u tehnike metode

a) evklidske razdalje  $r=2$

b) minimiziranje ...  $r=?$

$$\left( \sum_{k=1}^m |x_k - y_k|^r \right)^{1/r}$$



c) ~~Hamming~~  $r=1$  XOR  $\oplus$

d) Mahalanobis distance (eliminating the variable  
- inverse covariance matrix)  $\text{cov}^{-1}$  attribute)

single matching coefficient (two binary, contingency table)  
Jaccard coefficient (binary; ignore 00)  
cosine product (binary)

## Data exploration

- explore your dataset: possible na data
- statistics: mean, percentile, median, ...

visualization: plot, matrix, ... histogram

- feature product is not sufficient
- explains:
  - redundant
  - irrelevant
  - synthetic
  - highly correlated

## Linear algebra

Pearson coefficient

$[-1, 1]$

$$\text{corr}(x, y) = \frac{s_{xy}}{s_x s_y}$$

variance

standard deviation

$$x_i = a y_i + b$$





- recall (cp loss 1) =  $\frac{TP}{TP + FN}$
- specificity =  $\frac{TN}{TN + FP}$
- f1 score

## problem a model

- qualitative model building a description
- quantitative  $\Rightarrow$  statistical

||

black-box character a person function

- model is "representation" of data set:  
interpretability, a trade-off
- model is too simple: strong  
rule-based  
to NN
- a model is a cost function

## class imbalance problem

- very rare, good or bad like bird
- outlier cases  $\Rightarrow$  99% NEG, 1% POS  
 $\Downarrow$   
model will learn NEG,  
difficult to do a logistic
- outlier to : efficiency (neg: accuracy)


- Review :

criteria for (loss -  $\log$ )

criteria also (cost sensitive learning,  
class weights)

positive samples - others as background

- ROC curve is AUC





## rozhodovací strom

- hodina  $\Rightarrow$  časť

- užitok; časť  $\Rightarrow$  rozhodovací podmienky

- list  $\Rightarrow$  klasifikácia

- hierarchický reprezentatívny model

- 1 časť, 2 listy, 3 podmienky

- prvá podmienka je expon. množina

!!

- množina podmienok

!!


- množina podmienok (zjednotenie podmienok)

1. prvá podmienka  $\in D$  - je to množina podmienok

2. druhá podmienka (oslovná podmienka)

- rozhodovací strom  $D$  má množinu podmienok

- podmienka časť : typ "podmienka?"



- po cysfwrthwr a chydwrthwr gwrthodol sy'n  
(a) cyswrtwr gwrthodol

test nod atcudd

- a) binar : 2 nodnod, cyswrtwr
- b) spigite : disjunctif interval
- c) nominal/ordinal : k nodnod, cyswrtwr

- on test, mabwysu a chydwrthwr

(i) pwrthwr = (n) cyswrtwr

- cyswrtwr a chydwrthwr  

$$I(t) = \frac{n(i|t)}{n(t)} + \dots + \dots$$

nodnod a chydwrthwr  
 nodnod a chydwrthwr  
 nodnod a chydwrthwr  
 nodnod a chydwrthwr

information gain

- cyswrtwr a chydwrthwr test
- a chydwrthwr a chydwrthwr
- a chydwrthwr a chydwrthwr
- a chydwrthwr a chydwrthwr

$$I(t) = I(t) - \sum_{i'} \frac{n(i')}{n(t)} I(i')$$

entropy



1. specific entropii s<sub>spez</sub> w<sub>2</sub> S<sub>spez</sub>  $\bar{I}(t)$

2. ist entropii p<sub>irakt</sub> s<sub>spez</sub> w<sub>2</sub> S<sub>spez</sub>  $\bar{I}(t)$

3. w<sub>2</sub> S<sub>spez</sub> ist  $\bar{I}(t)$  S<sub>spez</sub> S<sub>spez</sub>

obt. q<sub>2</sub> w<sub>2</sub> S<sub>spez</sub> S<sub>spez</sub> (k<sub>2</sub> S<sub>spez</sub> w<sub>2</sub> S<sub>spez</sub> S<sub>spez</sub>)

## generalizare

- capacitatea pe care o are un sistem să generalizeze pe baza informațiilor dintr-un set de date
- $\text{generalizare} = \frac{\text{capacitatea să testeze corect}}{\text{capacitatea să generalizeze}}$

## prevenirea (overfitting)

- folosirea metodei de încercare și eroare
- alegerea unui set de date de testare
- alegerea unui set de date de antrenament
- alegerea unui set de date de validare
- principala metodă de prevenirea overfitting-ului este prin alegerea unui set de date de validare
- preferința pentru un model simplu

- o abordare sistematică:

**pre-training** - antrenarea sistemului (max. bias, min. variance, ...)

**post-training** - evaluarea sistemului

- lipsa de generalizare

## validarea metodei

**hold-out** - alegerea unui set de date (50/50 rule)



random subsampling - open source hold-out

cross validation - random n = 5 splits  
disjunct sets  $\rightarrow$  train

C3.2 bootstrap

## rule-based

- principle IF - THEN
- consequence  $\rightarrow$  consequent
- "principle position" -  $S_j$  "posed" is "principle" position
- view principle  $\rightarrow$  view result

1) coverage - solving obj. is p-systems

2) accuracy - solving p-systems obj. is "square" class label

- principle solving method using (posed as, task priority, new knowledge)

- using principle solving = using obj. method with "set" principle

(using using DEFAULT criterion)

## task-principle

- performance method - post-principle method using
  - reperformance method - re-solving, using solving method



$$S_{\alpha} S_{\beta} n \dot{c}_{\alpha\beta} \quad p_{\alpha} S_{\alpha} \dot{c}_{\alpha\beta} \quad (p_{\alpha} \dot{c}_{\alpha\beta})$$

- $f \in \mathcal{C}^n$        $n$ -step
- $\mathcal{E}$  linear      LEARN - ONE - RULE
- postulate       $p$ -system       $j$ -dimensional       $s$ -step       $\mathbb{R}^D$ ,  
 $a$        $n$        $p$ -system       $obj$        $p$        $obj$ -system
- $u \in \mathcal{C}^n$        $s$        $s$ -system       $j$ -dimensional       $p$ -system,  $s$ -step  
 $s$        $p$ -system       $obj$        $p$ -system       $p$ -system       $a$   
 $p$ -system       $s$        $(obj \in \mathcal{C}^n)$        $s$        $p$ -system       $obj$ -system
- $d$ -system       $n$ -dimensional       $j$        $s$ -step       $p$ -system       $obj$ -system  
 $a$        $j$ -step       $obj$ -system,       $n$ -step       $p$ -system       $obj$ -system,  
 $p$ -system       $s$        $n$ -step       $obj$ -system
- $p$ -system       $s$        $p$ -system       $s$        $p$ -system       $obj$ -system

RIPPER

- vorgegebene Eigenschaften
- spezifische Anforderungen (z.B. Kosten, Zeit, Qualität)
- Zielsetzung und Priorisierung der Aufgaben

- 4-566 f = 7-5 < 4.5 rules

- 4-566 f = 7-5 < 4.5 rules

- 4-566 f = 7-5 < 4.5 rules

- 4-566 f = 7-5 < 4.5 rules





## Bayes'sche Statistik

- 09 -

- $Y \in S = \text{discrete}$  probabilities of  $S$ -out:

$$\text{with: } P(Y | x) = \frac{P(x | Y) P(Y)}{P(x)}$$

- predicted  $S$  means  $x$  test features  $x$  population

- $x$  ... attributes  $Y$  ... class label

↑  
feature

- $P(Y)$  ... prior probabilities of  $S$ -out

$\bar{x}$  ... stat. feature (population)

$P(Y | x)$  ... posterior

$P(x)$  is constant

$\sigma^2$  ... var. /

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

- principle **Maximum** - **Posteriori**

$$\hat{y} = \arg \max_y P(x | Y = y) P(Y = y)$$

## Naïve Bayes

- probabilities of  $S$  probabilities necessary attributes and class (attributes ignore necessary conditions)

- therefore calculate joint probabilities

$$P(x_i | Y)$$

||  
↓

please to Bayes





# association analysis

- seller's site records
- products
- frequent item-sets
- typical market basket analysis
- items

transaction

item-sets

association principles

support count  $\sigma(X) = |\{t_i \in T \mid X \subseteq t_i\}|$

support  $s(X \rightarrow Y) \leftarrow \frac{\sigma(X \cup Y)}{\sigma(X)}$  transaction  $\sigma(X \cup Y)$

confidence  $c$   $X \subseteq Y$  recover

point transaction, time

item sets

# association rules

- observed exponential number of rules
- better use frequent item-sets
- minimum  $s_{min}$   $c_{min}$

solid transaction  $s_{min}$   $c_{min}$   $s_{min}$   $c_{min}$

item sets  $s_{min}$   $c_{min}$   $s_{min}$   $c_{min}$



$z = y^T - cost$

cost

- potic  $S_{j \rightarrow i}$  je  $j$  i  $i$  - etic,  $rež$   $j$   $rež$   $i$  -

- lift :  $= 1 \rightarrow$   $rež$   $i$   $> 1 \rightarrow$   $rež$   $i$   $< 1 \rightarrow$   $rež$   $i$

levicije

$IS$  -  $rež$

$\phi$  - koef.  $rež$

- of  $j$   $i$   $rež$   $i$   $rež$   $i$   $rež$   $i$

- kontingencije  $S_{j \rightarrow i}$

- Simpson  $rež$   $i$

$$\begin{aligned} lift(X \rightarrow Y) &= \frac{c(X \rightarrow Y)}{s(Y)} \rightarrow \frac{s(X \cup Y)}{s(X)} \\ &= \frac{N \cdot \sigma(X \cup Y)}{\sigma(X) \cdot \sigma(Y)} \end{aligned}$$

## Apriori

- generate frequent item-sets
- principle:  $\text{correct} \rightarrow \text{pruning} \rightarrow \text{frequent join}$   
tasks, frequent
- $\text{correct}, \text{pruning}, \text{infrequent nodes}$   
best frequent
- user define hasSo far, stop

## FP - Growth

- store FP tree
- find it. subtree all support count
- nodeid = pairs
- process 2 processes data set

## ECLAT

- user define data (true list)
- find patterns in ID transaction, find se  
unsatisfactory
- patterns, tid-list



- po redukcji  $\rightarrow$  nie  $\times$  generacji praktycznie

-  $\exists \{A, B\}$  nie  $\exists$   $S_1$   $A \rightarrow B$  i  $B \rightarrow A$

$\exists \{A, B, D\}$  — „ —  $AB \rightarrow D$   
 $AD \rightarrow B$   
 $DB \rightarrow A$

- skutecznie przesłane  $\{A, B\}$  i  $\{A, B, D\}$  i  $\{A, B, D\}$

stanie praktycznie a u  $\{A, B\}$  i  $\{A, B, D\}$  i

$\{A, B, D\}$  a  $\{A, B, D\}$  to  $\{A, B, D\}$  i  $\{A, B, D\}$

fr.  $\{A, B, D\}$





definiere

historisch

konzeptuell - obj. selber verstehen

## k-means metoda

- iterativni postupak
- do 4 različitih skupova
- prototip, centroid a medij

1) izbor se prototip

2) sporedni se određuju, baci k prototip a prijedlog se

3) prijedlog se prototip je za izostavljanje

4) oporavak se prototip nastavlja

- jezikovni prototip

- na skupovima različitih postrojenja

## prilici k-means

- različit se skupovi objekata a
- se dalji različitosti u skupovima

## ulaznici

- jezikovni a učitaj
- objekte učitaj učitaj



- Später reagiere ich noch

- vielleicht sind ja noch

- schließlich sind dies (Pistons, Pleistozän, ...)

## hierarchické skládání

- vizualizace dendrogramem

1) aglomerativní - spojujeme 2 sklady

2) divizivní - rozdělujeme sklady na singlety

## blízko sklady

kvantita

- single link / min

- complete link / max

- průměr (nezi min a max)

prototypy

- centroidy

- Wardova metoda

## histotický skládání

- hledáme hustotu objektů


- jak definovat hustotu?

a) center based - např. DBSCAN ( $k=4$ )

- řídící metoda hledá sklady

- nemusí být vždy dobrá - více informace





Ans: 6      NE: 5      (11)

$$\frac{6}{11} \log_2 \frac{6}{11} + \frac{5}{11} \log_2 \frac{5}{11} + 0.994$$

$$E + \sum$$

$$P(Y|x) = \frac{P(x|Y) P(Y)}{P(x)}$$

support count : 0      solution      X : Y      / use

confidence : 0.1      to      back      /      pos      X

MSE

$$E(c) = \sum_{i=1}^n (y_i - f(x_i))^2$$

$$f_1 - score = \frac{2TP}{2TP + FP + FN}$$

k-NN

$O(N \cdot m)$

$N$  ... point

bede

$m$  ... point

cl-ener